

Amazon Clothing Review Analysis and Recommendation

Nhóm nghiên cứu

Ngày 19 tháng 4 năm 2026

Nội dung trình bày

- 1 Giới thiệu đề tài
- 2 Tiền xử lý và EDA
- 3 Mô hình Phân tích Cảm xúc
- 4 Hệ thống Gợi ý (SVD)
- 5 Kết luận

1. Đặt vấn đề

- Thương mại điện tử phát triển mạnh, Amazon là một trong những nền tảng bán lẻ trực tuyến lớn nhất thế giới với hàng triệu đánh giá sản phẩm.
- Danh mục thời trang (Clothing, Shoes and Jewelry) có đặc thù là người mua không thể thử trực tiếp trước khi mua.
- Đánh giá (review) của khách hàng đóng vai trò như một nguồn thông tin tham khảo cốt lõi, quyết định trực tiếp đến hành vi mua hàng.

2. Thách thức thông tin

- Trải nghiệm mua sắm phụ thuộc lớn vào yếu tố cá nhân như kích cỡ (size), độ vừa vặn (fit).
- Sự gia tăng theo cấp số nhân của lượng dữ liệu đánh giá dẫn đến hiện tượng "quá tải thông tin" (Information Overload).
- Người dùng không thể đọc hết ý kiến để đưa ra quyết định, dễ bị lạc lối giữa số lượng sản phẩm quá lớn.

3. Mục tiêu nghiên cứu

Đề tài khai thác bộ dữ liệu Amazon Reviews 2023 để giải quyết bài toán kép:

- **Phân tích Cảm xúc (Sentiment Analysis):** Phân tích tự động hàng triệu văn bản đánh giá để thấu hiểu cảm xúc khách hàng.
- **Hệ thống Gợi ý (Recommendation System):** Xây dựng hệ thống gợi ý thông minh giúp cá nhân hóa trải nghiệm mua sắm.

4. Tiền xử lý dữ liệu lớn

- **Thách thức:** Xây dựng phương pháp xử lý bộ dữ liệu khổng lồ (hơn 22 triệu bản ghi, ~8.3GB) trên thiết bị cá nhân RAM 8GB. Việc dùng Pandas dẫn đến lỗi Out-Of-Memory.
- **Giải pháp Out-of-core Processing:**
 - Kỹ thuật Chunking (xử lý theo khối 100,000 dòng).
 - Định dạng lưu trữ Parquet giúp nén dữ liệu xuống 3-4GB và giảm chi phí I/O.

5. Phân tích Khám phá: Sự mất cân bằng nhãn

- Tập dữ liệu bộc lộ sự mất cân bằng vô cùng nghiêm trọng.
- Lớp Tích cực (Positive) chiếm 76.8%, lớp Tiêu cực (Negative) chỉ chiếm 14.6%.
- Tỷ lệ Mất cân bằng (IR) là 5.26, nghĩa là bình luận khen ngợi cao gấp hơn 5.3 lần bình luận chê bai.
- **Hệ quả:** Gây ra hiện tượng Overfitting đối với lớp đa số.

6. Phân tích Khám phá: Độ thưa thớt (Sparsity)

- 49.5% người dùng chỉ đánh giá đúng 1 lần (hiện tượng Cold-Start cực kỳ nặng).
- Kết quả tính toán cho thấy độ thưa thớt của tập dữ liệu lên tới 99.999490%.
- Đặc trưng văn bản cho thấy từ khóa "size" và "fit" xuất hiện dày đặc, khẳng định vấn đề kích cỡ là rào cản lớn nhất.

7. Bài toán Phân tích Cảm xúc

- **Mục tiêu:** Phân loại sắc thái bình luận thành 3 nhóm: Tích cực, Tiêu cực, Trung tính.
- **Tiêu chí tối ưu:** Thay vì dùng Accuracy, nhóm sử dụng F1-Macro làm thước đo tối thượng.
- F1-Macro ép mô hình phải hoạt động tốt trên cả 3 sắc thái cảm xúc độc lập.

8. Các phương pháp Baseline (Sơ lược)

Nhóm triển khai các thuật toán cơ bản làm Baseline để đối chiếu hiệu năng:

- **Học máy truyền thống:** Logistic Regression, SGD Classifier, Linear SVM, Random Forest.
- **Học sâu cơ bản:**
 - TextCNN (trích xuất n-grams nhưng hạn chế với câu dài).
 - BiLSTM (đọc câu theo hai hướng để hiểu ngữ cảnh "khen trước chê sau").

9. Trọng tâm: Mô hình DistilBERT

- DistilBERT là một phiên bản thu gọn của BERT.
- Khắc phục điểm yếu của các phương pháp trên bằng cách phân tích ngữ cảnh phức tạp của ngôn ngữ tự nhiên.
- Nhóm sử dụng phương pháp Transfer Learning, fine-tune mô hình trên 300,000 đánh giá.

10. Lý thuyết cơ chế Attention

- Sức mạnh của DistilBERT đến từ cơ chế Scaled Dot-Product Attention.
- Cơ chế này cho phép mô hình tính toán sự phụ thuộc lẫn nhau giữa mọi cặp từ trong câu, bất kể khoảng cách.
- Đây là chìa khóa giúp DistilBERT vượt trội hơn CNN và LSTM.

11. Công thức: Scaled Dot-Product Attention

$$Attention(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (1)$$

Giải thích ký hiệu:

- Q : Ma trận Query biểu diễn các từ khóa truy vấn.
- K : Ma trận Key biểu diễn các từ khóa khóa.
- V : Ma trận Value biểu diễn giá trị của từ khóa.
- d_k : Kích thước không gian vector.

12. Xử lý Mất cân bằng nhãn

- Nếu chỉ dùng hàm mất mát bình thường, mô hình sẽ bị "mù" với bình luận chê bai (Negative).
- Giải pháp: Áp dụng kỹ thuật gán trọng số nghịch đảo (Inverse Class Weights) được tích hợp trực tiếp vào hàm mất mát Weighted Cross-Entropy Loss.

13. Công thức: Weighted Cross-Entropy Loss

$$Loss = - \sum_{c=1}^M w_c y_{o,c} \log(p_{o,c}) \quad (2)$$

Giải thích ký hiệu:

- M : Số lượng lớp (3 lớp cảm xúc).
- w_c : Trọng số phạt của lớp c (nhân trọng số lớn hơn cho lớp thiếu số để phạt nặng khi dự đoán sai).
- $y_{o,c}$: Nhãn thực tế của dữ liệu.
- $p_{o,c}$: Xác suất mô hình dự đoán cho lớp c .

14. Kết quả thực nghiệm Sentiment Analysis

Model	F1-Macro	F1-Weighted	F1-Neg	F1-Neu	F1-Pos
Logistic Regression	0.5472	0.7008	0.5673	0.2913	0.7830
TextCNN	0.6656	0.8249	0.7027	0.3898	0.9042
BiLSTM	0.6843	0.8431	0.7161	0.4142	0.9226
DistilBERT	0.7005	0.8554	0.7461	0.4243	0.9311

Kết luận: DistilBERT là mô hình tốt nhất với F1-Macro đạt 0.7005, chứng tỏ khả năng thấu hiểu ngôn ngữ vượt trội.

15. Bài toán Hệ thống Gợi ý

- Nhằm giải quyết bài toán "Information Overload", giúp tìm ra sản phẩm phù hợp sở thích cá nhân giữa hàng triệu lựa chọn.
- Nhóm so sánh 4 thuật toán thuộc các trường phái khác nhau: Collaborative Filtering, Content-Based, Deep Learning.

16. Các phương pháp gợi ý Baseline (Sơ lược)

- **Content-Based Filtering:** Phụ thuộc vào sự tương đồng văn bản TF-IDF (Title, Description) giữa các sản phẩm.
- **Neural Collaborative Filtering (NCF):** Thay thế tích vô hướng bằng mạng nơ-ron đa tầng (MLP) để học các tương tác phi tuyến tính.

17. Trọng tâm: Phân rã Ma trận (SVD)

- Phân rã ma trận (Matrix Factorization - SVD) là kỹ thuật chủ đạo trong Lọc cộng tác.
- Hoạt động bằng cách phân rã ma trận tương tác R (rất thưa thớt) thành hai ma trận đặc trưng ẩn có chiều thấp cho người dùng (P) và sản phẩm (Q).
- Thuật toán tự động học các Latent Features mà không cần biết chính xác đặc trưng đó là gì (màu sắc, size...).

18. Công thức: Dự đoán điểm số SVD

$$\hat{r}_{ui} = \mu + b_u + b_i + q_i^T p_u \quad (3)$$

Giải thích ký hiệu:

- $\hat{r}_{ui}$: Điểm số dự đoán cho tương tác giữa người dùng u và sản phẩm i .
- μ : Rating trung bình trên toàn hệ thống.
- b_u, b_i : Độ lệch (bias) cá nhân của người dùng u và sản phẩm i .
- p_u, q_i : Vector đặc trưng ẩn (latent factors) của người dùng và sản phẩm.

19. Công thức: Tối ưu hóa SVD

Mô hình tối ưu hóa bằng cách cực tiểu hóa hàm mất mát có điều hạn chế chính quy hóa để tránh Overfitting.

$$\min_{p,q,b} \sum_{(u,i) \in \kappa} (r_{ui} - \hat{r}_{ui})^2 + \lambda(\|p_u\|^2 + \|q_i\|^2 + b_u^2 + b_i^2) \quad (4)$$

Giải thích ký hiệu:

- $(u, i) \in \kappa$: Tập hợp các tương tác thực tế đã quan sát được trong ma trận.
- r_{ui} : Điểm đánh giá thực tế (ground truth).
- λ : Tham số chính quy hóa (Regularization term).

20. Kết quả thực nghiệm Hệ thống gợi ý

Thuật toán	RMSE	MAE	Precision@10
SVD	1.2258	0.9479	0.0002
SVD++	1.2330	0.9649	0.0
NCF	1.2372	0.9748	0.0002
Content-Based	N/A	N/A	0.0

Nhận xét: SVD cho kết quả RMSE thấp nhất (1.2258), chứng tỏ các phương pháp phân rã ma trận tuyến tính vẫn cực kỳ hiệu quả đối với bài toán dự đoán rating trên dữ liệu thưa.

21. Phân tích: Thách thức trong gợi ý Top-K

Các chỉ số Precision/Recall ở mức rất thấp, lý do cốt lõi:

- **Độ thừa thớt cực độ:** Độ thừa 99.9999% khiến cơ hội tìm chính xác 1 sản phẩm trong 1.26 triệu items là cực kỳ thấp.
- **Đặc thù ngành hàng:** Hành vi mua sắm quần áo mang tính rời rạc, ngẫu nhiên. Người dùng ít khi mua lại cùng một sản phẩm.
- **Giới hạn văn bản:** Content-Based thất bại (0.0) do thiếu đặc trưng thị giác (màu sắc, kiểu dáng).

22. Kết luận đạt được

- **Data Pipeline:** Xử lý thành công dữ liệu thô khổng lồ trong điều kiện giới hạn thông qua Chunking và Parquet.
- **Phân tích cảm xúc:** Mô hình DistilBERT chứng minh sức mạnh của kiến trúc Transformer với F1-Macro 0.7005.
- **Hệ thống gợi ý:** SVD cho thấy hiệu năng dự báo ổn định nhất với RMSE 1.2258.

23. Hạn chế của đề tài

- Độ thưa thớt cực đoan khiến các chỉ số Top-K chưa đạt kỳ vọng cao.
- Việc gợi ý trang phục phụ thuộc rất nhiều vào cảm quan hình ảnh, nhưng mô hình mới chỉ khai thác văn bản và lịch sử rating (thiếu hụt dữ liệu thị giác).
- Các mô hình tĩnh (Static Models) như SVD chưa phản ánh trọn vẹn sự thay đổi theo xu hướng thời trang (Trends).

24. Hướng phát triển tương lai

Để khắc phục hạn chế, nhóm đề xuất:

- **Gợi ý đa phương thức (Multi-modal):** Tích hợp thêm đặc trưng hình ảnh từ CNN (ResNet, ViT) để mô hình "nhìn" được sản phẩm.
- **Gợi ý theo chuỗi (Sequential):** Dùng RNN/Transformer dự đoán sản phẩm tiếp theo dựa trên chuỗi hành vi trong một phiên (session).
- **Hybrid Approach:** Dùng dự báo từ DistilBERT để điều chỉnh trọng số rating (VD: 4 sao nhưng text chê → giảm trọng số), giúp SVD học tín hiệu "sạch" hơn.